

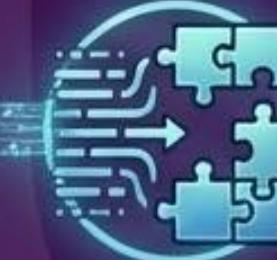


IA de Synthèse de Texte en Français

Système de Résumé
Automatique en
Français



Transformer entraîné
from scratch



Tokenisation
SentencePiece



Architecture
personnalisée et
entraînement
supervisé sans modèle
pré-entraîné.



CONTEXTE

Problématique & Objectif du Projet

Pourquoi le résumé automatique ?

- Volumes importants de textes à traiter quotidiennement
- Besoin croissant de synthèse rapide et efficace
- Reformulation intelligente sans copier le contenu original
- Gain de temps pour les chercheurs et professionnels

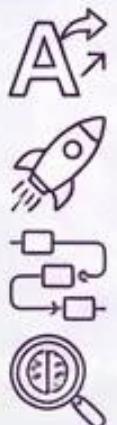


Objectif du projet

Résumé **abstractif** : génération de nouvelles formulations

Modèle développé **from scratch** sans transfert

- Pipeline complet maîtrisé de bout en bout
- Compréhension approfondie des mécanismes internes



Le résumé automatique représente une tâche particulièrement complexe car elle nécessite à la fois une compréhension profonde du contenu source et une capacité de reformulation cohérente.



DONNÉES : Constitution du Dataset d'Entraînement



Source

Articles de presse en français provenant de sources journalistiques variées

Structure



text : article complet

summary : résumé cible

title : injecté comme signal



Séparation

Split strict en trois ensembles : train, validation et test sans chevauchement



Le titre est utilisé comme signal sémantique supplémentaire pour faciliter l'apprentissage from scratch et guider la génération du résumé.



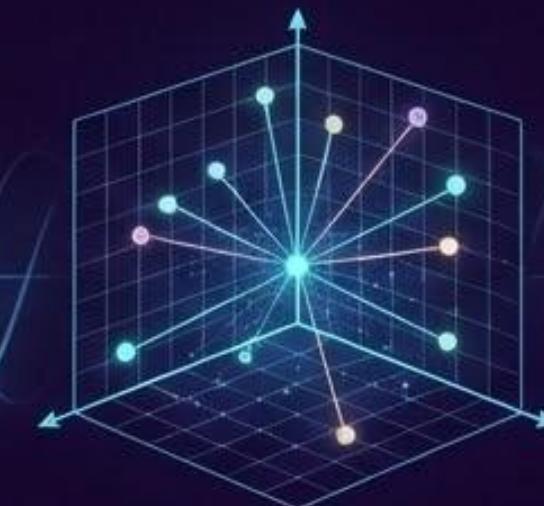
TOKENISATION & EMBEDDINGS

Tokenisation SentencePiece



Approche **Unigram** pour la segmentation du texte français avec un vocabulaire optimisé de **16 000 tokens**, permettant une couverture équilibrée des mots courants et des termes spécialisés.

Couche d'Embeddings



Embeddings appris **from scratch** durant l'entraînement :

- ✖ Dimension vectorielle : **256**
- ~~~~~ Encodage positionnel sinusoïdal
- ⚙️ Initialisation aléatoire contrôlée
- 👉 Aucune représentation pré-entraînée



L'**absence d'embeddings pré-entraînés** signifie que toutes les représentations sémantiques sont construites uniquement à partir des données d'entraînement disponibles.





ARCHITECTURE

Architecture Transformer Encoder-Decoder

Couches

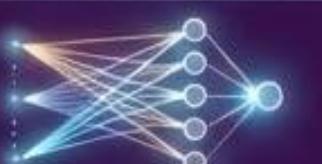
4 couches encodeur pour analyser le texte source

4 couches décodeur pour générer le résumé



Attention

4 têtes d'attention multi-têtes pour capturer différentes relations sémantiques



Feed-Forward

Dimension intermédiaire de 1024 dans les couches feed-forward

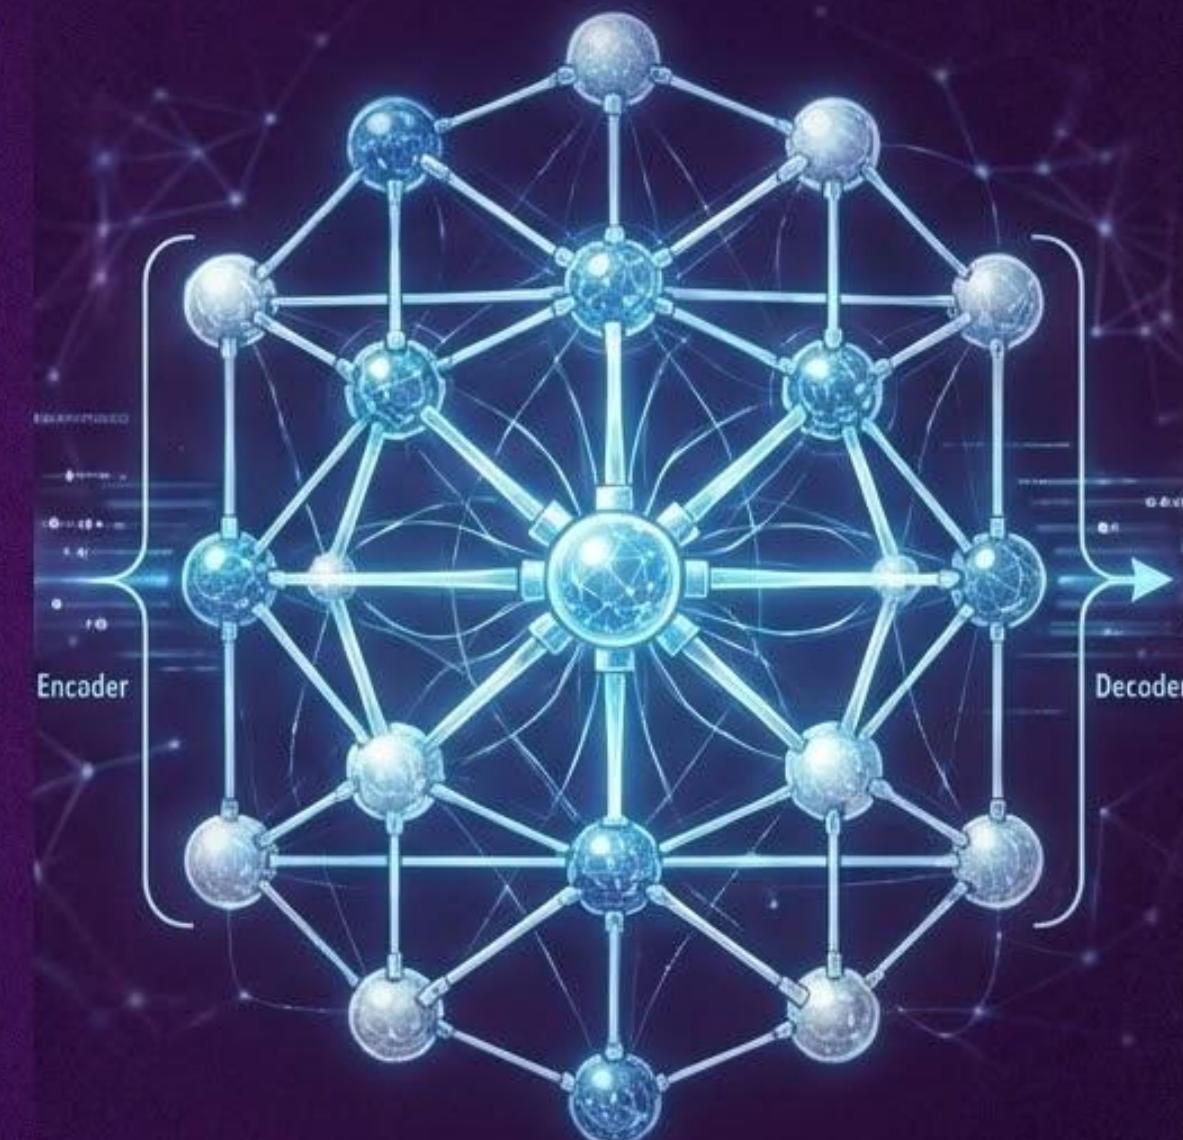


Régularisation

Dropout de 0.1 pour prévenir le surapprentissage



L'encodeur transforme le texte source en représentations contextuelles, tandis que le décodeur génère le résumé token par token en utilisant l'attention croisée. Architecture similaire aux standards modernes mais entièrement implémentée et entraînée from scratch.





CONFIGURATION

Stratégie d'Entraînement

Hyperparamètres & Technique



Optimiseur AdamW

Learning rate : 3×10^{-4}



Learning rate 3×10^{-4}



Fonction de perte

Cross-entropy + label smoothing (0.1)



Teacher Forcing

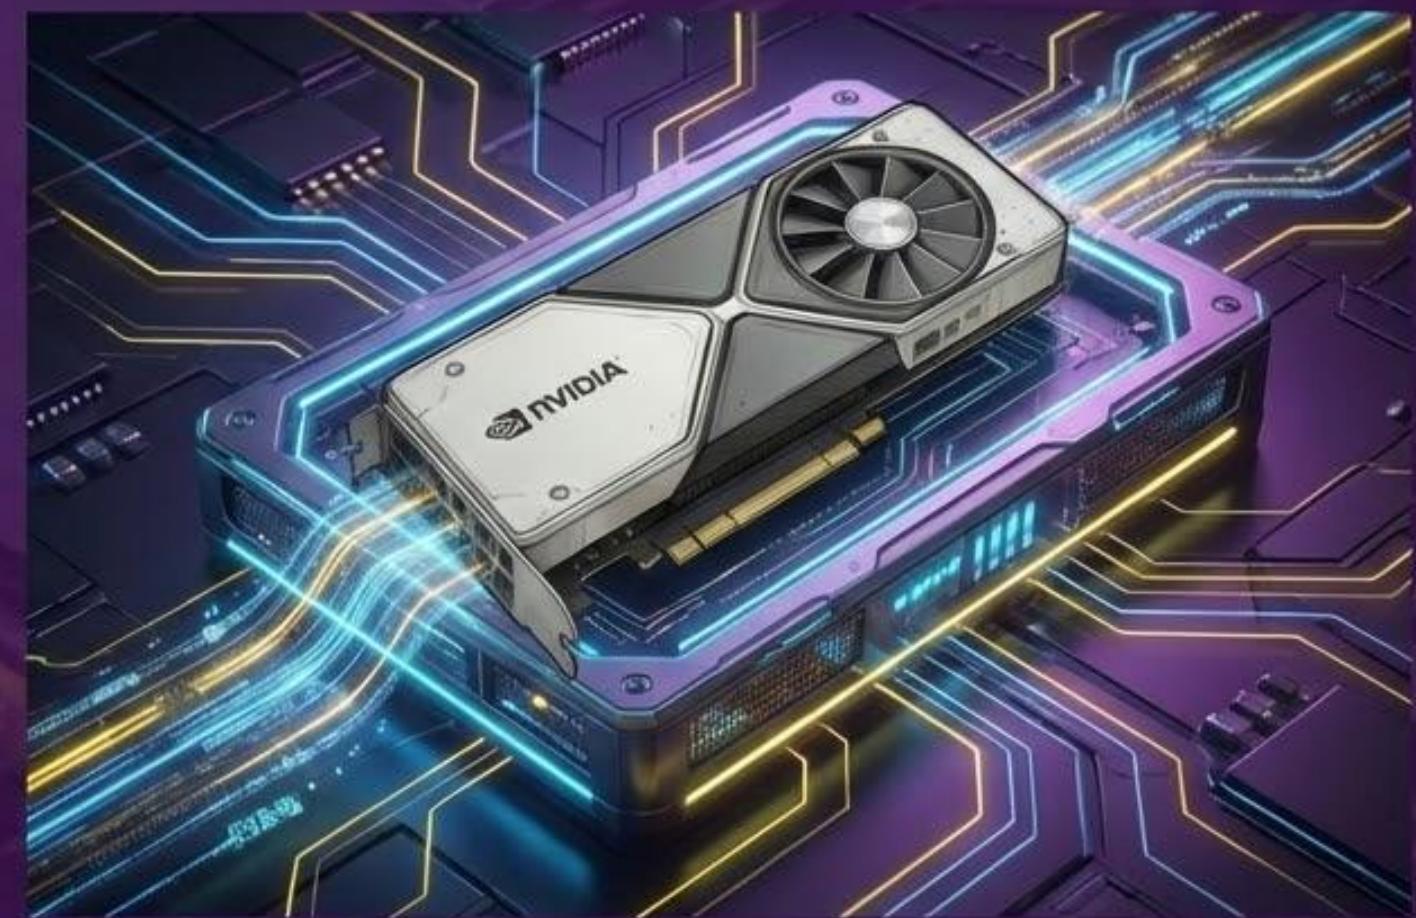
Utilisation des tokens de référence pendant l'entraînement



Gradient Clipping

Stabilisation de l'entraînement

Infrastructure



Entraînement sur GPU RTX 4060 Laptop avec batches limités par epoch pour accélérer les itérations tout en conservant la stabilité d'apprentissage.



RÉSULTATS

Évaluation Quantitative des Performances

Évolution des pertes durant l'entraînement



ROUGE-1

0.15

Chevauchement de unigrammes

ROUGE-2

0.02

Chevauchement de bigrammes

ROUGE-L

0.12

Plus longue sous-séquence commune

Les scores ROUGE restent modestes, ce qui est attendu et cohérent pour un modèle entraîné entièrement from scratch sans phase de pré-entraînement sur de larges corpus.



ANALYSE QUALITATIVE

Exemples de Résumés Générés

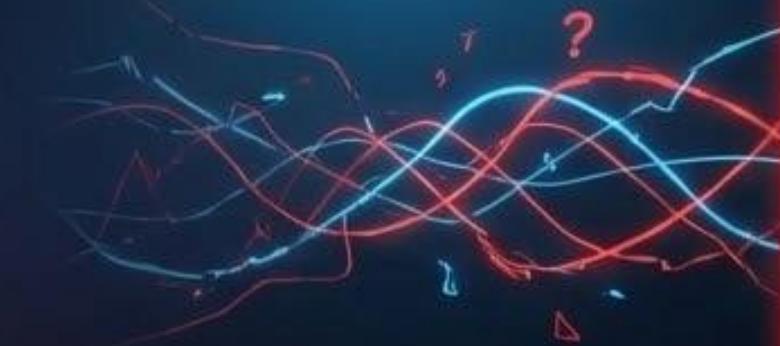
Observations positives

- ✓ Syntaxe globalement correcte
- ✓ Style de résumé appris avec succès
- ✓ Structure cohérente des phrases
- ✓ Formulations fluides et naturelles



Défis identifiés

- ⚠ Contenu parfois incohérent
- ⚠ Imprécisions factuelles
- ⚠ Écart entre forme et fond
- ⚠ Pertinence sémantique variable



Le modèle a appris la forme du résumé — sa structure et son style typique — avant d'acquérir une compréhension profonde du fond sémantique et de la précision factuelle.



⚠ LIMITES

Analyse Critique & Limites Observées

Problèmes identifiés

Hallucinations

Génération d'informations non présentes dans le texte source



Répétitions

Motifs répétitifs dans les résumés générés



Précision factuelle

Faible fidélité aux faits du document original

Précision factuelle

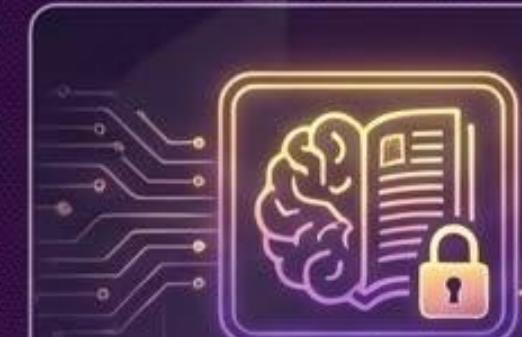
Faible fidélité aux faits du document original



Complexité intrinsèque

exposition restreinte aux modulations restreintes aux variations linguistiques

Causes sous-jacentes



Absence de pré-entraînement

pas de connaissance linguistique préalable

Corpus limité

exposition restreinte aux variations linguistiques



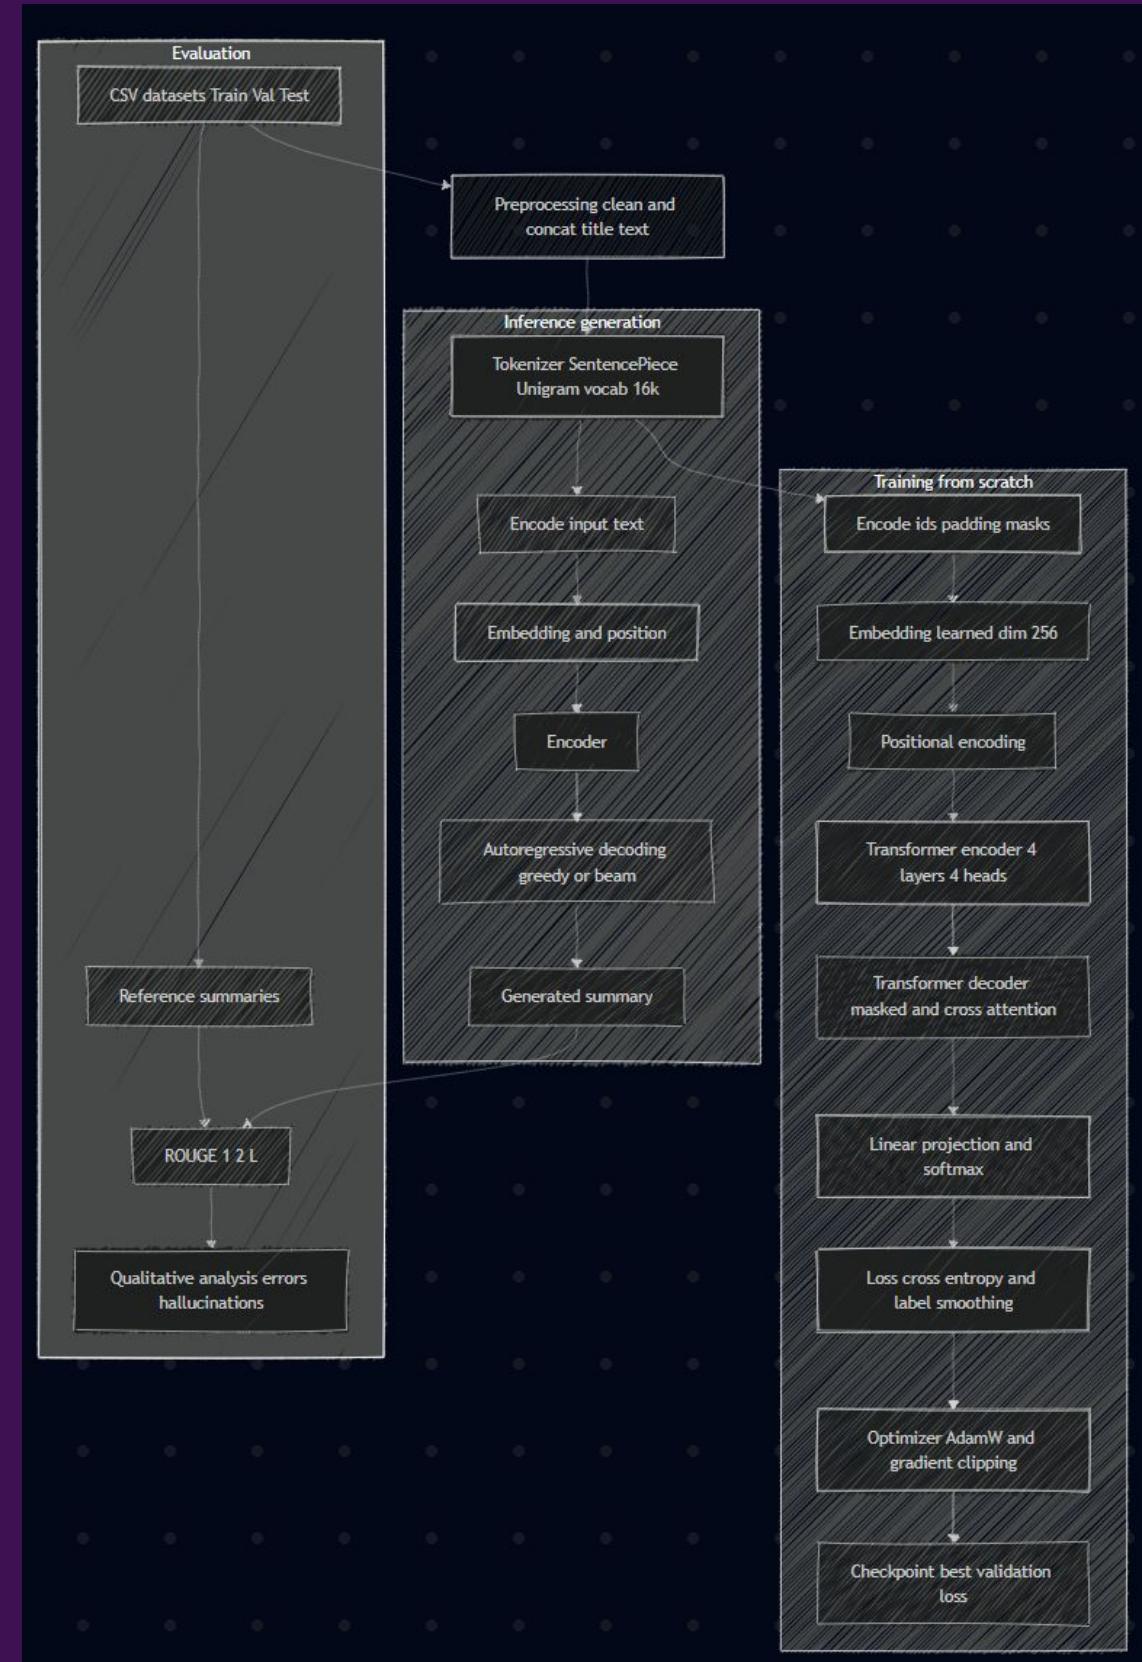
Complexité intrinsèque

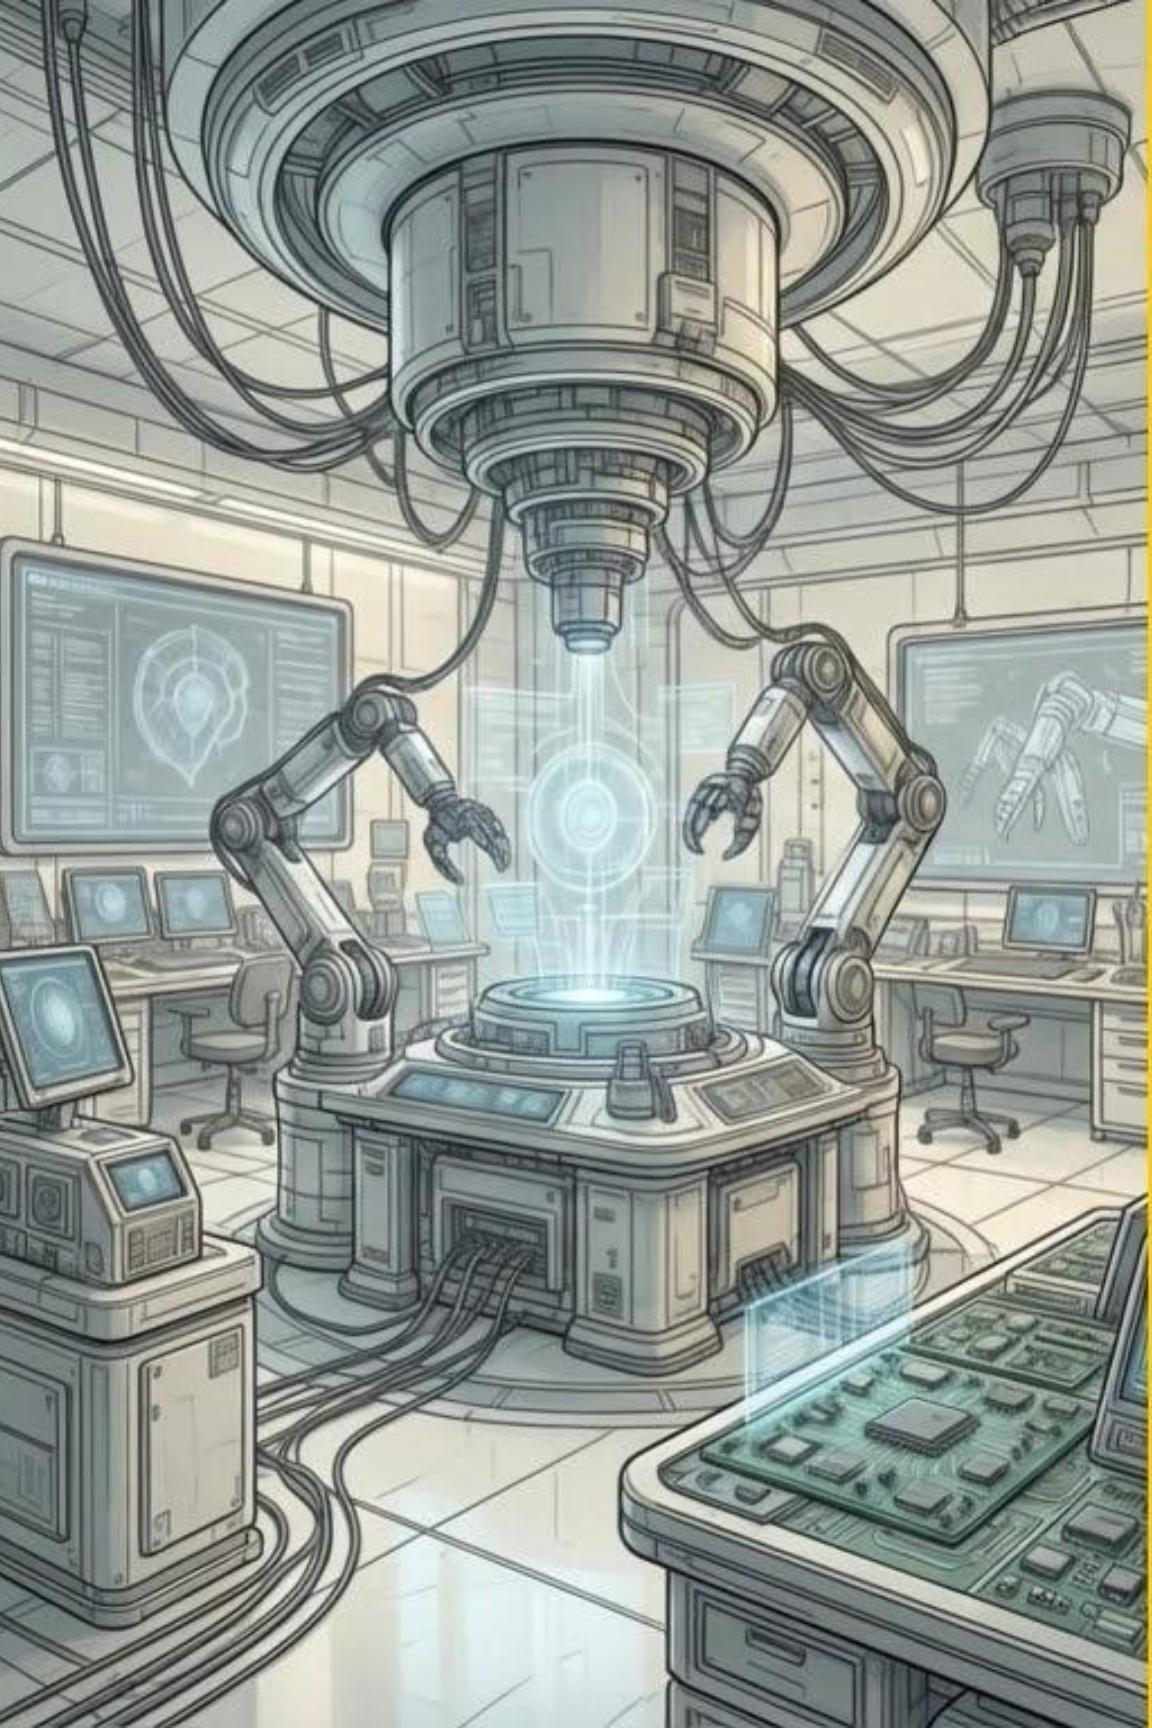
la tâche de résumé abstractif est fondamentalement difficile

Ces limitations sont typiques et attendues pour les modèles génératifs entraînés from scratch sans phase de pré-entraînement extensive.



PIPELINE :





PERSPECTIVES

Conclusion & Perspectives d'Amélioration



Bilan

Pipeline conçue fonctionnellement, architecture moderne maîtrisée, résultats cohérents avec les contraintes



Perspectives

Pré-entraînement auto-supervisé, beam search avec contraintes, corpus plus large et diversifié

Ce projet met en évidence le rôle central du pré-entraînement dans les performances des modèles de langage modernes.

01

Pré-entraînement auto-supervisé

Pré-entraînement auto-supervisé
Apprentissage sur de vastes corpus non annotés

02

Beam search optimisé

Amélioration de la qualité de génération avec contraintes

03

Extension du corpus

Diversification et augmentation des données d'entraînement